

COLA DE CODIGOS - PROVA DE METODOS ESTATISTICOS

Copie o molde e troque: ARQUIVO / COLUNA / NUMERICA / GRUPO / VARIABEL_X / VARIABEL_Y.

1) ABRIR E OLHAR A BASE

```
import pandas as pd
import altair as alt
import matplotlib.pyplot as plt

df = pd.read_csv('ARQUIVO.csv')
df.head()
df.shape
df.dtypes
```

Excel: df = pd.read_excel('ARQUIVO.xls')

2) 1 OUALITATIVA - FREQUENCIA

```
df['COLUNA'].value_counts()
```

Tabela + porcentagem:

```
tabela = df['COLUNA'].value_counts().reset_index()
tabela.columns = ['Categoria', 'Frequencia']
tabela['Porcentagem'] = (
tabela['Frequencia'] / tabela['Frequencia'].sum()
) * 100
```

3) GRAFICOS - OUALITATIVA

```
tabela.set_index('Categoria').Porcentagem.plot.bar()
tabela.set_index('Categoria').Porcentagem.plot.pie()
```

Altair barras:

```
alt.Chart(tabela).mark_bar().encode(
x=alt.X("Categoria:N"),
y="Porcentagem:Q"
)
```

4) 1 OUANTITATIVA - RESUMO

```
df['COLUNA'].describe()
df['COLUNA'].mean()
df['COLUNA'].median()
df['COLUNA'].max()
```

describe: mean=media | std=DP | 25%=Q1 | 50%=mediana | 75%=Q3 | min/max.

5) HISTOGRAMA

```
alt.Chart(df).mark_bar().encode(
alt.X("COLUNA:Q", bin=True),
y='count()'
)
```

Com intervalo definido:

```
alt.Chart(df).mark_bar().encode(
alt.X("COLUNA:Q", bin=alt.Bin(step=5)),
y='count()'
)
```

Pandas (como no trabalho):

```
ax = df['COLUNA'].plot.hist(bins=20)
ax.set_xlabel('Eixo X')
ax.set_ylabel('Numero de observacoes')
ax.set_title('Titulo')
```

INTERPRETAR HISTOGRAMA

FORMA -> CENTRO -> VARIABILIDADE -> VALORES ATIPICOS. Simetrica/sem atipicos -> media + DP. Assimetrica/com atipicos -> mediana + AIQ.

6) BOXPLOT

```
alt.Chart(df).mark_boxplot(extent=1.5).encode(
y='COLUNA:Q'
).properties(width=200)
```

Comparar arupos:

```
alt.Chart(df).mark_boxplot(extent=1.5, size=40).encode(
alt.X("NUMERICA:Q"),
alt.Y("GRUPO:N")
)
```

Ou: df.boxplot(column='NUMERICA', by='GRUPO')

7) AIO / POTENCIAIS ATIPICOS

```
AIQ = Q3 - Q1
limite_inferior = Q1 - 1.5 * AIQ
limite_superior = Q3 + 1.5 * AIQ
```

8) 2 QUANTITATIVAS - SCATTERPLOT

```
alt.Chart(df).mark_circle().encode(
  alt.X("VARIABEL_X"),
  alt.Y("VARIABEL_Y"),
  tooltip=['VARIABEL_X', 'VARIABEL_Y']
)
```

9) CORRELACAO

```
df[['VARIABEL_X', 'VARIABEL_Y']].corr(numeric_only=True)
```

Positiva = crescem juntas | negativa = uma sobe e outra tende a cair | perto de 0 = pouca associacao linear. **Nao prova causalidade.**

10) 2 QUALITATIVAS - TABELA DUPLA

```
tabela_dupla = df.groupby(
  ['CATEGORIA_1', 'CATEGORIA_2']
).size().unstack(1)
```

tabela_dupla

11) CRIAR FAIXAS - pd.cut()

```
df['Faixa'] = pd.cut(
  x=df['IDADE'],
  bins=[0, 18, 30, 55, 100],
  labels=['Child', 'Young Adult', 'Adult', 'Senior'],
  right=True
)
```

12) SERIE TEMPORAL

```
df['Data'] = pd.to_datetime(df.Data)
```

```
alt.Chart(df).mark_line().encode(
  x='Data',
  y='COLUNA'
)
```

Extrair ano: df['Year'] = df.Data.dt.year

13) FILTROS RAPIDOS

```
df[df['COLUNA'] > valor]
df[df['COLUNA'] < valor]
df[df.CATEGORIA != "NomeDaCategoria"]
```

14) ERROS MAIS COMUNS

NameError: rode a celula que cria a variavel/tabela antes. **KeyError:** nome da coluna errado - confira df.head() ou df.columns. Data como texto -> pd.to_datetime().

MAPA RELAMPAGO

Se pedir...	Use...
1 qualitativa	value_counts() -> % -> barras/pizza
1 quantitativa	describe() + histograma
Numerica por grupos	boxplot
2 quantitativas	scatterplot + corr()
2 qualitativas	groupby().size().unstack(1)
Tempo	pd.to_datetime() + mark_line()

ORDEM NA PROVA: ler pergunta -> identificar variaveis -> classificar (qualitativa/quantitativa) -> escolher bloco -> trocar nomes -> rodar -> interpretar.