

GUIA DE PROVA - METODOS ESTATISTICOS

Foco: receber uma base nova, identificar o que a questao pede, adaptar os codigos dos notebooks e interpretar o resultado.

COMO USAR ESTE GUIA

Na prova, voce nao precisa decorar todos os codigos. Precisa reconhecer o tipo de problema, localizar um codigo parecido nos notebooks e trocar os nomes da base/variaveis. A sequencia abaixo foi montada a partir das Aulas 4, 6, 11 e 14 e do seu trabalho de Powerlifting.

REGRA-MAE: 1) conhecer a base -> 2) identificar tipo das variaveis -> 3) decidir se e analise de uma ou duas variaveis -> 4) escolher grafico/medida -> 5) interpretar.

1. ABRIR E CONHECER UMA BASE

Imports que aparecem nas aulas:

```
import pandas as pd
import altair as alt
```

No seu trabalho voce tambem usou Matplotlib:

```
import matplotlib.pyplot as plt
```

Abrir CSV:

```
df = pd.read_csv('arquivo.csv')
```

Abrir Excel:

```
df = pd.read_excel('arquivo.xls')
```

Primeiras linhas:

```
df.head()
df.head(2)
```

Outros comandos de reconhecimento que aparecem nos notebooks:

```
df.shape
df.dtypes
df.tail()
df.max()
df.min()
```

O que trocar: normalmente apenas **df** pelo nome da sua base e o nome do arquivo.

2. FILTRAR, ORDENAR E SELECIONAR

Ordenar uma variavel:

```
df.sort_values('Variavel', ascending=False)
```

Filtrar linhas por uma condicao:

```
df[df.Variavel > valor]
df[df['Variavel'] < valor]
```

Excluir uma categoria de uma analise:

```
df[df.Categoria != "NomeDaCategoria"]
```

Remover uma linha especifica:

```
df.drop([0])
```

Isso apareceu na Aula 14 para verificar como um hospital individual alterava a correlacao.

3. VARIÁVEL QUALITATIVA - FREQUENCIAS

Se a questao pedir distribuicao de sexo, curso, equipamento, regio, categoria etc., pense primeiro em **frequencias**.

Contagem simples:

```
df['Categoria'].value_counts()
```

Transformar contagem em tabela:

```
tabela = df['Categoria'].value_counts().reset_index()
tabela.columns = ['Categoria', 'Frequencia']
```

Calcular porcentagem - modelo do seu trabalho:

```
tabela['Porcentagem'] = (
    tabela['Frequencia'] /
    tabela['Frequencia'].sum())
```

```
) * 100  
  
tabela
```

Interpretacao: diga qual categoria aparece mais, qual aparece menos e a participacao aproximada de cada uma.

4. GRAFICO DE BARRAS - QUALITATIVA

Versao simples do Pandas, usada na Aula 4:

```
tabela.set_index('Categoria').Porcentagem.plot.bar()
```

Versao simples do Altair, seguindo o padrao da Aula 4:

```
alt.Chart(tabela).mark_bar().encode(  
  x=alt.X("Categoria:N"),  
  y="Porcentagem:Q"  
)
```

Lembrete do Altair: :N = nominal/categoria; :Q = quantitativa.

5. GRAFICO DE PIZZA/SETORES

Pandas - mesmo padrao usado na Aula 4 e no seu trabalho:

```
tabela.set_index('Categoria').Porcentagem.plot.pie()
```

Altair - padrao da Aula 4:

```
alt.Chart(tabela).mark_arc().encode(  
  theta="Porcentagem:Q",  
  color=alt.Color("Categoria:N"),  
  tooltip=["Categoria:N", "Porcentagem:Q"]  
)
```

Use quando houver poucas categorias e fizer sentido mostrar participacao do total.

6. VARIÁVEL QUANTITATIVA - COMEÇO DA ANÁLISE

Se a questão pedir análise de idade, renda, peso, nota, TotalKg etc., pense em **distribuição + centro + variabilidade**.

Resumo numérico principal:

```
df['Variavel'].describe()
```

Ou para a base inteira:

```
df.describe()
```

O que ler no describe:

Saída	Leitura
count	quantidade de valores válidos
mean	média
std	desvio padrão
min	mínimo
25%	Q1
50%	mediana / Q2
75%	Q3
max	máximo

Cálculos isolados que aparecem na Aula 11:

```
df['Variavel'].mean()  
df['Variavel'].median()  
df['Variavel'].max()
```

Regra importante: média e desvio padrão combinam melhor com distribuições aproximadamente simétricas e sem valores atípicos importantes. Mediana e AIQ são mais adequados quando há assimetria/valores atípicos.

7. HISTOGRAMA - DISTRIBUIÇÃO DE QUANTITATIVA

Altair - padrão mais recorrente da Aula 6 e Aula 11:

```
alt.Chart(df).mark_bar().encode(  
  alt.X("Variavel:Q", bin=True),  
  y="count()  
)
```

Escolher largura das classes (bins):

```
alt.Chart(df).mark_bar().encode(  
  alt.X("Variavel:Q", bin=alt.Bin(step=5)),  
  y="count()  
)
```

No seu trabalho você usou Pandas/Matplotlib:

```
ax = df['Variavel'].plot.hist(bins=20)  
  
ax.set_xlabel('Nome do eixo X')  
ax.set_ylabel('Número de observações')  
ax.set_title('Título do gráfico')
```

Como interpretar o histograma: FORMA (simétrica/assimétrica), CENTRO, VARIABILIDADE e VALORES ATÍPICOS. Essa estrutura aparece explicitamente na Aula 6.

Cuidado: a Aula 11 mostra que a escolha da largura dos intervalos pode mudar bastante a visualização do padrão.

8. MÉDIA, MEDIANA E VALORES EXTREMOS

A Aula 11 compara média com e sem um valor muito alto. Modelo de filtro + média:

```
df[df.Categoria != "CasoExtremo"]['Variavel'].mean()
```

A ideia principal: a **média não é resistente**; a **mediana é resistente**. Não basta olhar apenas média e mediana para afirmar a forma da distribuição: a própria aula manda conferir o gráfico.

9. AIQ E REGRA DE VALOR ATÍPICO

AIQ = Q3 - Q1.

Regra trabalhada na Aula 11:

```
limite_inferior = Q1 - 1.5 * AIQ  
limite_superior = Q3 + 1.5 * AIQ
```

Um valor fora desse intervalo é tratado como **potencial valor atípico** pela regra 1,5 x AIQ.

10. BOXPLOT

Altair - um boxplot:

```
alt.Chart(df).mark_boxplot(extent=1.5).encode(  
  y='Variavel:Q'  
)
```

Na Aula 11, **extent=1.5** destaca valores além da regra 1,5 x AIQ. Também aparece **extent='min-max'** para ir do mínimo ao máximo.

Comparar grupos - estrutura da Aula 11:

```
alt.Chart(base_com_grupos).mark_boxplot(extent=1.5, size=40).encode(  
  alt.X("Variavel:Q"),  
  alt.Y("Grupo:N")  
)
```

No seu trabalho:

```
df.boxplot(column='TotalKg', by='Sex')
```

Interpretar comparando: mediana, tamanho da caixa (AIQ), deslocamento geral, assimetria e valores atípicos.

11. DESVIO PADRAO

Na Aula 11 aparece a biblioteca statistics:

```
from statistics import stdev, mean, median

mean(lista)
stdev(lista)
median(lista)
```

Outra forma usada na aula:

```
pd.DataFrame(lista).describe().loc[['mean', 'std']]
```

Interpretacao: desvios padrao menores indicam observacoes mais proximas entre si; maiores indicam maior heterogeneidade/variabilidade.

12. SERIES TEMPORAIS

Se a base tiver uma variavel de tempo/data e a questao pedir evolucao ao longo do tempo:

Grafico de linha:

```
alt.Chart(df).mark_line().encode(
    x='ano',
    y='Variavel'
)
```

Converter coluna para data:

```
df['Data'] = pd.to_datetime(df.Data)
```

Extrair ano:

```
df["Year"] = df.Data.dt.year
```

Extrair mes-dia:

```
df['MonthDay'] = df.Data.dt.strftime('%m-%d')
```

Variacao percentual de um periodo para outro:

```
df['aumento_percentual'] = df['Variavel'].pct_change() * 100
```

Reamostrar por dia - codigo da Aula 6:

```
serie_dia = df.set_index(
    pd.to_datetime(df['Data'])
).resample('d').Count.sum()
```

Na interpretacao da serie, procure tendencia geral, mudancas de ritmo, picos/quedas e periodos fora do padrao.

13. DUAS VARIAVEIS QUANTITATIVAS - DISPERSAO

Aula 14 - diagrama de dispersao:

```
alt.Chart(df).mark_circle().encode(
    alt.X("VariavelX"),
    alt.Y("VariavelY"),
    tooltip=['VariavelX', 'VariavelY']
)
```

Use quando a pergunta for: existe relacao/associacao entre duas variaveis numericas?

14. CORRELACAO

Codigo literal da Aula 14:

```
df[['VariavelX', 'VariavelY']].corr(numeric_only=True)
```

A interpretacao principal: sinal positivo -> tendem a crescer juntas; negativo -> uma tende a cair quando a outra cresce; proximo de zero -> pouca associacao linear.

Aula 14 tambem mostra que a correlacao pode ser sensivel a uma observacao individual:

```
df.drop([0])[['VariavelX', 'VariavelY']].corr(numeric_only=True)
```

Datasaurus: correlacao parecida nao garante grafico parecido. Sempre que possivel, olhe o scatterplot junto com a correlacao.

15. DUAS VARIAVEIS QUALITATIVAS - TABELA DE DUPLA ENTRADA

Formato matricial da Aula 14:

```
tabela_dupla = df.groupby(
    ['Categoria1', 'Categoria2']
).size().unstack(1)
```

```
tabela_dupla
```

Adicionar totais:

```
tabela_dupla.loc['Total', :] = tabela_dupla.sum(axis=0)
tabela_dupla.loc[:, 'Total'] = tabela_dupla.sum(axis=1)
```

Preencher células vazias com zero:

```
tabela_dupla.fillna(0, inplace=True)
```

Formato longo:

```
tabela_long = df.groupby(
    ['Categoria1', 'Categoria2']
).size()
```

Distribuição condicional por Categoria1:

```
tabela_long /
tabela_long.groupby(level=0).transform(sum) * 100
```

Distribuição condicional por Categoria2:

```
tabela_long /
tabela_long.groupby(level=1).transform(sum) * 100
```

16. BARRAS SEGMENTADAS / NORMALIZADAS

Contagens absolutas - Aula 14:

```
alt.Chart(
    tabela_long.reset_index().rename(columns={0: 'contagem'})
).mark_bar().encode(
    x=alt.X('contagem'),
    y='Categoria1',
    color='Categoria2'
)
```

Percentuais / barra normalizada:

```
alt.Chart(
    tabela_long.reset_index().rename(columns={0: 'contagem'})
).mark_bar().encode(
    x=alt.X('contagem', stack="normalize"),
    y='Categoria1',
    color='Categoria2'
)
```

17. CRIAR CATEGORIAS A PARTIR DE UMA VARIÁVEL NUMÉRICA

Aula 14 - `pd.cut()`:

```
df['Faixa'] = pd.cut(
    x=df['Idade'],
    bins=[0, 18, 30, 55, 100],
    labels=['Child', 'Young Adult', 'Adult', 'Senior'],
    right=True
)
```

Serve para transformar idade numérica, por exemplo, em faixas etárias.

18. MAPA DE DECISAO PARA A PROVA

A questao pede...	Primeiro codigo / caminho
Conhecer a base	head(), shape, dtypes
Uma qualitativa	value_counts() -> porcentagem -> barras/pizza
Uma quantitativa	describe() + histograma
Centro	mean() / median()
Variabilidade	std no describe / AIQ
Atipicos	Q1, Q3, AIQ + boxplot extent=1.5
Comparar quantitativa entre grupos	boxplot por grupo
Evolucao no tempo	pd.to_datetime + mark_line()
Duas quantitativas	mark_circle() + corr()
Duas qualitativas	groupby(...).size().unstack(1)
Criar faixas	pd.cut()

19. CHECKLIST QUANDO RECEBER A BASE

1. Rode head() e veja as colunas.
2. Se necessario, rode dtypes.
3. Leia a pergunta e marque quais variaveis ela cita.
4. Classifique: qualitativa ou quantitativa?
5. E uma variavel ou duas?
6. Escolha o bloco de codigo correspondente neste guia.
7. Troque apenas nome da base e nomes das variaveis.
8. Rode o codigo.
9. Leia o grafico/numeros.
10. Escreva uma interpretacao em palavras.

20. COMO ESCREVER A INTERPRETACAO

Histograma: 'A distribuicao apresenta... O centro esta em torno de... Os valores variam... Ha/nao ha indicios de valores atipicos.'

Boxplot comparativo: 'O grupo A apresenta mediana maior/menor. O grupo B tem maior/menor dispersao. Ha valores potencialmente atipicos em...'

Scatterplot/correlacao: 'O grafico sugere associacao positiva/negativa/fraca entre X e Y. A correlacao e... Isso descreve associacao, nao prova causalidade.'

Categoricas: 'A categoria X concentra a maior parcela dos registros, seguida de Y...'

21. ERROS QUE MAIS PODEM TE TRAVAR

NameError: voce usou uma variavel/tabela antes de cria-la. Rode as celulas anteriores na ordem.

KeyError: nome da coluna esta errado. Confira com **df.head()** ou **df.columns**.

Grafico vazio/estranho: confira tipo da coluna, dados ausentes e se voce escolheu a variavel certa.

Data nao funciona como tempo: use **pd.to_datetime()** antes.

22. O QUE EU PRIORIZARIA PARA ESTUDAR

Prioridade maxima: head(), value_counts(), porcentagem, describe(), histograma, media/mediana, AIQ/desvio padrao, boxplot, scatterplot e corr().

Depois: groupby + unstack, distribuicoes condicionais, pd.cut(), series temporais.

Se voce dominar a logica desses blocos e souber trocar os nomes das variaveis, ja consegue enfrentar boa parte de uma prova pratica com base nova.